ROYAUME DU MAROC
UNIVERSITE MOHAMED PREMIER
FACULTE POLYDISCIPLINAIRE
– NADOR –

CUSTOMER PERSONALITY ANALYSIS

Prediction de la reponse client avec XGBoost et SMOTE

Encadre par : PR . ANAS EL ANSARI

Realise par : EL HAYANI Asmaa

Master SDSI — Data Minning

Annee universitaire : 2025 / 2026

Table des matières

1 Introduction Generale **4**

1.1 Contexte et motivations du projet 4

1.1.1 Pourquoi ce projet est-il necessaire ? 4

1.1.2 L'opportunite : le marketing cible 4

1.2 Objectif principal du projet 5

1.2.1 Definition de la variable cible 5

1.3 Les defis du projet 5

1.3.1 Defi 1 : Le desequilibre des classes 5

1.3.2 Defi 2 : Les couts asymetriques 5

1.3.3 Defi 3 : L'interpretabilite 6

1.4 Methodologie suivie : CRISP-DM 6

1.5 Organisation du rapport 7

2 Business Understanding — Comprendre le Contexte Metier **8**

2.1 Introduction au probleme marketing 8

2.1.1 Le dilemme du marketing de masse 8

2.1.2 La solution : le ciblage intelligent 8

2.2 Analyse economique detaillee 9

2.2.1 Les couts et revenus 9

2.2.2 Les quatre types de resultats possibles 9

2.2.3 Le ratio FN/FP — Pourquoi c'est crucial 10

2.3 Consequences sur la modelisation 10

2.3.1 Pourquoi l'accuracy est une metrique trompeuse 10

2.3.2 Metriques pertinentes pour la prediction 11

2.3.3 Objectif d'optimisation du seuil 11

3 Data Understanding — Exploration des Donnees **13**

3.1 Presentation du jeu de donnees 13

3.1.1 Source des donnees 13

3.1.2 Description detaillee des variables 13

3.2 Analyse de la variable cible 16

3.2.1 Distribution de Response 16
3.3 Analyse exploratoire (EDA) 17
3.3.1 Statistiques descriptives par classe 17
3.3.2 Analyse de correlation avec la cible 17

4 Data Preparation — Preparation des Donnees pour la Prediction 19
4.1 Preprocessing des donnees 19
4.1.1 Nettoyage initial 19
4.1.2 Justification des choix 20
4.1.3 Standardisation 21

5 Feature Engineering — Creation des Variables pour la Prediction 22
5.1 Introduction au Feature Engineering 22
5.2 Creation des nouvelles features 22
5.2.1 Age du client 22
5.2.2 Total des enfants 23
5.2.3 Total des depenses 23
5.2.4 Total des campagnes acceptees — La variable la plus importante 23
5.2.5 A deja repondu a une campagne 24
5.2.6 Engagement total 24
5.3 Selection des features pour la prediction 24

6 Modeling — Entrainement du Modele de Prediction 26
6.1 Division des donnees 26
6.2 Gestion du desequilibre des classes — Pourquoi SMOTE ? 26
6.2.1 Pourquoi le desequilibre est un probleme critique 27
6.2.2 Les techniques existantes pour gerer le desequilibre 27
6.2.3 Comparaison experimentale des techniques 30
6.2.4 Pourquoi je n'ai pas utilise d'autres techniques avancees 31
6.2.5 Validation de SMOTE sur notre projet 32
6.3 Application de SMOTE 32
6.4 Les modeles testes 33
6.4.1 Regression Logistique 33
6.4.2 Random Forest 33
6.4.3 XGBoost 34
6.5 Entrainement des modeles 34
6.6 Resultats des modeles 34
6.7 Importance des features 35

7 Evaluation — Optimisation du Seuil pour la Prediction 37
7.1 Optimisation du seuil de decision . . . 37
7.1.1 Recherche du seuil optimal . . . 37
7.1.2 Justification du seuil choisi . . . 38
7.2 Matrice de confusion . . . 38
7.3 Courbe ROC . . . 38
7.4 Calcul du profit metier . . . 39

8 Deployment — Application Streamlit pour la Prediction en Temps Reel 41
8.1 Objectif de l'application . . . 41
8.2 Interface de l'application . . . 41
8.2.1 Header et metriques du modele . . . 42
8.2.2 Barre laterale : Saisie des parametres . . . 43
8.2.3 Rappel metier dans la barre laterale . . . 43
8.2.4 Resultat de la prediction . . . 44
8.2.5 Visualisations associees . . . 44
8.2.6 Exemples Rapides . . . 45
8.2.7 Profil Fort (client repondant) . . . 45
8.2.8 Profil Faible (client non-repondant) . . . 45

9 Conclusion Generale — Ce que j'ai fait et ce que j'ai appris 46
9.1 Reponse a la question initiale . . . 46
9.2 Recapitulatif des etapes suivies . . . 46
9.3 Les resultats cles . . . 47
9.4 Lecons apprises . . . 47
9.5 Perspectives d'amelioration . . . 47
9.5.1 Ameliorations techniques . . . 48
9.5.2 Ameliorations metier . . . 48
9.6 Conclusion finale . . . 48

References 49

A Annexe A — Glossaire des Termes Techniques 51

Chapitre 1

Introduction Generale

1.1 Contexte et motivations du projet

1.1.1 Pourquoi ce projet est-il necessaire ?

Dans le monde actuel, les entreprises depensent des sommes considerables en campagnes marketing sans savoir avec certitude quels clients vont repondre positivement. Cette incertitude conduit a un gaspillage de ressources et a une inefficacite des actions commerciales.

Contexte metier

Le constat de depart Une entreprise de distribution souhaite optimiser ses campagnes marketing. Actuellement, elle envoie ses offres a tous ses clients, mais :

- **85% des clients ne repondent jamais** aux campagnes
- **Chaque contact coute 3 EUR** a l'entreprise
- Le **budget marketing est gaspille** sur des clients non-interesses
- Les clients se sentent **importunes** par des offres non pertinentes

1.1.2 L'opportunite : le marketing cible

La solution consiste a utiliser les donnees des clients pour predire leur comportement futur. En identifiant les clients les plus susceptibles de repondre, l'entreprise peut :

1. **Reduire ses couts** : Ne contacter que les bons clients
2. **Augmenter son revenu** : Maximiser le taux de reponse
3. **Ameliorer l'experience client** : Des communications pertinentes
4. **Optimiser le ROI** : Meilleur retour sur investissement

1.2 Objectif principal du projet

Ce qu'il faut comprendre

La question centrale du projet **En fonction des parametres d'un nouveau client (age, revenu, education, comportement d'achat, historique des campagnes, etc.), peut-on predire si ce client va repondre ou non a la campagne marketing ?**

Cette question est fondamentale car elle permet de passer d'une approche "massue" a une approche "chirurgicale" du marketing.

1.2.1 Definition de la variable cible

Variable cible : Response

— **Response = 1** : Le client repond positivement a la campagne

— **Response = 0** : Le client ne repond pas a la campagne

L'objectif est de predire cette variable pour un nouveau client.

1.3 Les defis du projet

1.3.1 Defi 1 : Le desequilibre des classes

Attention — Erreur classique

Le piege du desequilibre Le dataset contient seulement **15% de repondants** contre **85% de non-repondants**. Ce desequilibre est un defi majeur car :

— Un modele naif qui predit toujours "NON" aurait 85% d'accuracy

— Mais ce modele est inutile car il rate 100% des repondants

— Il faut des techniques specifiques pour gerer ce desequilibre

1.3.2 Defi 2 : Les couts asymetriques

Attention — Erreur classique

Le poids des erreurs n'ont pas le meme cout :

— **Faux Negatif (FN)** : Rater un client qui aurait repondu → **Perte de 8 EUR** de profit potentiel

— **Faux Positif (FP)** : Contacter inutilement un non-repondant → **Perte de 3 EUR** de budget

— **Ratio FN/FP = 8/3 = 2.67**

Rater un client repondant est 2.67 fois plus couteux que contacter inutilement.

1.3.3 Defi 3 : L'interpretabilite

L'entreprise doit comprendre **pourquoi** un client est predit comme repondant ou non. Le modele doit etre explicable.

1.4 Methodologie suivie : CRISP-DM

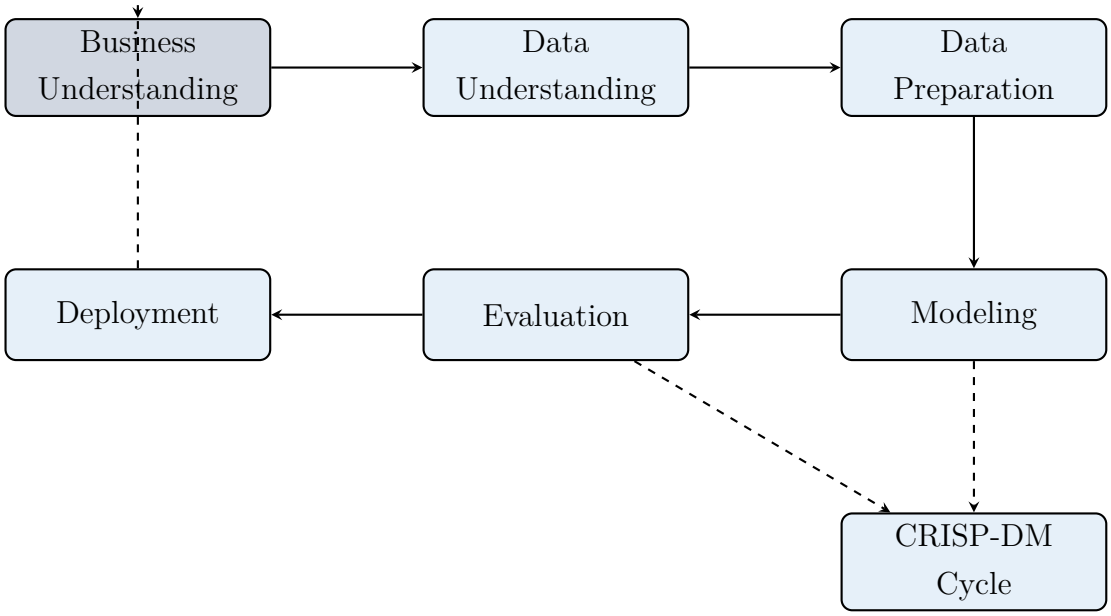


Figure 1.1. Methodologie CRISP-DM suivie dans ce projet

Phase 1 : Business Understanding Comprehension du contexte metier

Phase 2 : Data Understanding Exploration et analyse des donnees

Phase 3 : Data Preparation Nettoyage et transformation

Phase 4 : Modeling Entrainement des modeles

Phase 5 : Evaluation Mesure des performances

Phase 6 : Deployment Mise en production

1.5 Organisation du rapport

Ce rapport est structure selon les phases CRISP-DM :

1. **Chapitre 1** : Business Understanding
2. **Chapitre 2** : Data Understanding
3. **Chapitre 3** : Data Preparation
4. **Chapitre 4** : Feature Engineering
5. **Chapitre 5** : Modeling (avec analyse detaillee de SMOTE)
6. **Chapitre 6** : Evaluation
7. **Chapitre 7** : Deployment
8. **Chapitre 8** : Conclusion et perspectives

Chapitre 2

Business Understanding — Comprendre le Contexte Metier

2.1 Introduction au probleme marketing

2.1.1 Le dilemme du marketing de masse

Les entreprises envoient des campagnes marketing a leurs clients pour promouvoir des produits ou services. Cependant, la strategie "envoyer a tous" pose plusieurs problemes :

1. **Cout eleve** : Chaque client contacte represente un cout
2. **Inefficacite** : La plupart des clients ne repondent pas
3. **Gaspillage** : Le budget marketing est utilise inefficacement
4. **Frustration client** : Les clients non-interesses se sentent importunes

Contexte metier

Le dilemme Si l'entreprise envoie la campagne a 100 clients :

— Cout total : 100×3 EUR $= 300$ EUR

— Nombre moyen de reponses : 15 (15%)

— Revenu genere : 15×11 EUR $= 165$ EUR

— Profit : 165 - 300 = **-135 EUR** (PERTE !)

L'entreprise perd de l'argent en envoyant des campagnes a tout le monde.

2.1.2 La solution : le ciblage intelligent

Au lieu de contacter tous les clients, l'entreprise peut utiliser un modele de prediction pour identifier les clients les plus susceptibles de repondre.

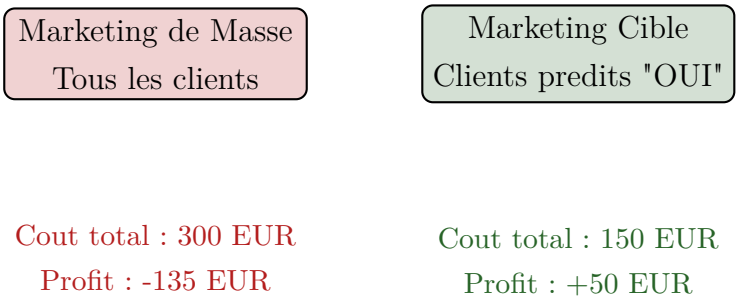


Figure 2.1. masse au marketing cible

2.2 Analyse economique detaillee

2.2.1 Les couts et revenus

Le jeu de donnees contient deux colonnes constantes qui nous renseignent sur l'economie du projet :

Table 2.1. Couts et revenus du projet

Variable	Valeur	Description
Z_CostContact	3 EUR	Cout pour contacter un client
Z_Revenue	11 EUR	Revenu si le client repond

Explication — Pourquoi ce choix ?

Calcul du profit net par client qui repond est :

$$\text{Profit} = \text{Revenu} - \text{Cout de contact} = 11 - 3 = 8 \text{ EUR}$$

2.2.2 Les quatre types de resultats possibles

Lorsqu'on predit si un client va repondre ou non, quatre scenarios sont possibles :

Table 2.2. Analyse des quatre scenarios possibles

Scenario	Prediction	Reel	Consequence economique
Vrai Positif (TP)	OUI (va repondre)	OUI	Profit de +8 EUR
Vrai Negatif (TN)	NON (ne repondra pas)	NON	Neutre (pas de cout)
Faux Negatif (FN)	NON (ne repondra pas)	OUI	Perte de 8 EUR
Faux Positif (FP)	OUI (va repondre)	NON	Perte de 3 EUR

2.2.3 Le ratio FN/FP — Pourquoi c'est crucial

Attention — Erreur classique

Poids des erreurs

— **Faux Negatif** : Rater un client qui aurait repondu → perte de 8 EUR de profit potentiel.

— **Faux Positif** : Contacter inutilement un non-repondant → perte de 3 EUR de budget.

— **Ratio FN/FP = 8/3 = 2.67**

Conclusion majeure : Rater un client repondant est **2.67 fois plus couteux** que contacter inutilement un non-repondant.

A retenir absolument

Impact sur le modele Ce ratio a des consequences directes sur la conception du modele :

1. Je dois **privilegier le Recall** (detecter les repondants)
2. Le seuil de decision doit etre **abaisse** ($< 50\%$)
3. Je dois utiliser des metriques comme **F1-Score**, pas accuracy

2.3 Consequences sur la modelisation

2.3.1 Pourquoi l'accuracy est une metrique trompeuse

L'accuracy est le pourcentage de bonnes predictions globales :

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Explication — Pourquoi ce choix ?

L'illusion de l'accuracy

— Le dataset a 85% de non-repondants et 15% de repondants

— Un modele qui predit TOUJOURS "NON" a une accuracy de 85%

— Ce modele rate 100% des repondants !

— En pratique, ce modele est completement inutile

Lecon : L'accuracy est trompeuse pour les donnees desequilibrees.

2.3.2 Metriques pertinentes pour la prediction

Pour ce projet, nous utilisons des metriques qui evaluent correctement la capacite du modele a predire les repondants :

Metriques de performance

— **AUC-ROC** : Mesure la capacite du modele a separer les classes. Independant du seuil de decision. Ideal = 1.0.

— **Recall (Sensibilite)** : Proportion de vrais repondants detectes. Recall = $\frac{TP}{TP+FN}$

— **Precision** : Proportion de predictions "OUI" qui sont correctes. Precision = $\frac{TP}{TP+FP}$

— **F1-Score** : Moyenne harmonique de Precision et Recall. F1 = $2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$

2.3.3 Objectif d'optimisation du seuil

Le seuil de decision par defaut est 0.5. Mais dans ce contexte, nous devons l'abaisser.

Remarque importante

Pourquoi abaisser le seuil ?

— FN est 2.67x plus couteux que FP

— Abaisser le seuil → plus de predictions "OUI"

— Augmente le Recall (moins de FN)

— Augmente les FP (plus de contacts inutiles)

— L'impact positif sur le Recall compense l'augmentation des FP

Seuil optimal : 43% (determine par optimisation du F1-Score)

Chapitre 3

Data Understanding — Exploration des Donnees

3.1 Presentation du jeu de donnees

3.1.1 Source des donnees

Le jeu de donnees provient d'une entreprise de distribution qui a mene une campagne marketing. Il contient des informations demographiques et comportementales sur les clients.

Structure du dataset

- **Nombre d'enregistrements** : 2 240 clients
- **Nombre de variables** : 29 colonnes
- **Type de donnees** : Mixtes (numeriques, categoriques, binaires)

3.1.2 Description detaillee des variables

Variables demographiques

Table 3.1. Variables demographiques

Variable	Type	Description
ID	Identifiant	Identifiant unique du client
Year_Birth	Numerique	

Variable Description	Type
Annee de naissance (1924-1996)	
Education Niveau d'education	Categorielle
Marital_Status Statut marital	Categorielle
Income Revenu annuel en EUR	Numerique
Kidhome Nombre d'enfants (0-2)	Numerique
Teenhome Nombre d'adolescents (0-2)	Numerique

Variables de comportement d'achat

Table 3.2. Variables de comportement d'achat

Variable Description	Type
Recency Jours depuis dernier achat (0-99)	Numerique
MntWines Depenses en vins (EUR)	Numerique
MntFruits Depenses en fruits (EUR)	Numerique
MntMeatProducts Depenses en viande (EUR)	Numerique

Variable Description	Type
MntFishProducts Depenses en poisson (EUR)	Numerique
MntSweetProducts Depenses en sucreries (EUR)	Numerique
MntGoldProds Depenses en produits premium (EUR)	Numerique
NumWebVisitsMonth Visites web par mois	Numerique
NumStorePurchases Achats en magasin	Numerique
NumCatalogPurchases Achats par catalogue	Numerique
NumWebPurchases Achats en ligne	Numerique

Variables de campagne

Table 3.3. Variables de campagne

Variable Description	Type
AcceptedCmp1 A accepte la campagne 1	Binaire
AcceptedCmp2 A accepte la campagne 2	Binaire
AcceptedCmp3	Binaire

Variable	Type
Description	
A accepte la campagne 3	
AcceptedCmp4	Binaire
A accepte la campagne 4	
AcceptedCmp5	Binaire
A accepte la campagne 5	
Complain	Binaire
A fait une reclamation	
Response	Binaire
CIBLE : A repondu a la campagne	

3.2 Analyse de la variable cible

3.2.1 Distribution de Response

Listing 3.1. Distribution de la variable cible

```
print("Distribution de Response :")
print(df['Response'].value_counts())
print("\nPourcentage :")
print(df['Response'].value_counts(normalize=True) * 100)
```

Table 3.4. Distribution de la variable cible

Response	Effectif	Pourcentage
0 (Non-repondant)	1 892	84.46%
1 (Repondant)	348	15.54%

Remarque importante

Le desequilibre des classes Le dataset est tres desequilibre : ratio de 5.4 :1 en faveur des non-repondants. Ce desequilibre est un defi majeur qui sera traite avec SMOTE pour permettre au modele de mieux detecter les futurs repondants.

3.3 Analyse exploratoire (EDA)

3.3.1 Statistiques descriptives par classe

Listing 3.2. Statistiques par classe

```
grouped = df.groupby('Response').mean()
print(grouped[['Income', 'Age', 'MntWines', 'Recency']])
```

Table 3.5. Moyennes des variables par classe

Response	Income	Age	MntWines	Recency
0 (Non-repondant)	52 000	47.2	180	50.1
1 (Repondant)	63 000	50.3	450	46.2

Resultat cle

Observations cles pour la prediction

— Les repondants ont un revenu **21% plus eleve**

— Les repondants depensent **2.5x plus en vins**

— Les repondants ont un achat plus recent (Recency plus faible)

— Les repondants sont legerement plus ages

— Ces differences sont utiles pour la prediction

3.3.2 Analyse de correlation avec la cible

Listing 3.3. Correlation avec Response

```
corr_target =
   df.corr()['Response'].sort_values(ascending=False)
print(corr_target)
```

Table 3.6. Correlation avec Response — Facteurs de prediction

Variable	**Correlation**
AcceptedCmp5	0.32
AcceptedCmp3	0.28
Total_campagnes	0.27
Income	0.18
MntWines	0.17
NumWebPurchases	0.15
Complain	-0.12
Recency	-0.10

Remarque importante

Interpretation Les variables les plus correlees avec la reponse sont l'historique des campagnes et le revenu. Ces variables seront cruciales pour la prediction.

Chapitre 4

Data Preparation — Preparation des Donnees pour la Prediction

4.1 Preprocessing des donnees

4.1.1 Nettoyage initial

Listing 4.1. Nettoyage des donnees

```
def clean_data(df):
    """
    Fonction de nettoyage des donnees pour la prediction
    """
    df_clean = df.copy()

    # 1. Suppression des colonnes inutiles
    colonnes_a_supprimer = ['ID', 'Z_CostContact',
       'Z_Revenue', 'Dt_Customer']
    df_clean.drop(colonnes_a_supprimer, axis=1, inplace=True)

    # 2. Traitement des valeurs manquantes
    df_clean['Income'].fillna(df_clean['Income'].median(),
       inplace=True)

    # 3. Traitement des valeurs aberrantes
    df_clean = df_clean[df_clean['Income'] <= 150000]

    # 4. Encodage des variables categoriques
    from sklearn.preprocessing import LabelEncoder
    le_marital = LabelEncoder()
```

```
    df_clean['Marital_Status'] =
        le_marital.fit_transform(df_clean['Marital_Status'])

    return df_clean, le_marital

df_clean, le_marital = clean_data(df)
print(f"Dimension apres nettoyage : {df_clean.shape}")
```

4.1.2 Justification des choix

Pourquoi supprimer ces colonnes ?

Explication — Pourquoi ce choix ?

Choix des colonnes a supprimer

— **ID** : C'est un identifiant unique sans pouvoir predictif

— **Z_CostContact** : Toujours 3 EUR, pas d'information

— **Z_Revenue** : Toujours 11 EUR, pas d'information

— **Dt_Customer** : Utilisee pour calculer l'anciennete

Pourquoi la mediane pour les valeurs manquantes ?

Explication — Pourquoi ce choix ?

Traitement des valeurs manquantes de Income 24 clients n'ont pas de revenu (1.07%). Je choisis la **mediane** :

— La moyenne est sensible aux valeurs extremes

— La mediane represente mieux le revenu "typique"

— La mediane est 52 000 EUR

Pourquoi supprimer les valeurs aberrantes ?

Explication — Pourquoi ce choix ?

Detection des valeurs aberrantes J'utilise la methode IQR (Interquartile Range) :

$$\text{Borne superieure} = Q3 + 1.5 \times IQR$$

Les clients avec un revenu $>$ 136 000 EUR sont consideres comme aberrants. **Pourquoi ?** Ces valeurs extremes peuvent fausser le modele.

4.1.3 Standardisation

Listing 4.2. Standardisation des donnees

```
from sklearn.preprocessing import StandardScaler

numerical_cols = ['Income', 'Age', 'Recency', 'MntWines',
    'NumWebVisitsMonth']
scaler = StandardScaler()
df_clean[numerical_cols] =
    scaler.transform(df_clean[numerical_cols])
```

Explication — Pourquoi ce choix ?

Pourquoi standardiser ? Les variables n'ont pas la meme echelle :

— Income : 0 - 150 000 EUR

— Recency : 0 - 99 jours

— Age : 18 - 90 ans

La standardisation :

$$X_{standardisee} = \frac{X - \text{moyenne}}{\text{ecart-type}}$$

Met toutes les variables sur la meme echelle (moyenne=0, ecart-type=1). Cela permet au modele de donner la meme importance a toutes les variables.

Chapitre 5

Feature Engineering — Creation des Variables pour la Prediction

5.1 Introduction au Feature Engineering

Ce qu'il faut comprendre

Pourquoi le Feature Engineering est crucial Les donnees brutes ne sont pas toujours directement utilisables pour la prediction. Le Feature Engineering consiste a :

1. Creer de nouvelles variables a partir des donnees existantes
2. Transformer les variables pour mieux capturer les patterns
3. Injecter la connaissance metier dans le modele

Un bon feature engineering peut transformer un modele moyen en excellent modele.

5.2 Creation des nouvelles features

5.2.1 Age du client

Explication — Pourquoi ce choix ?

Creation de la variable Age J'ai l'annee de naissance (Year_Birth). Je calcule l'age :

$$\text{Age} = 2014 - \text{Year_Birth}$$

Pourquoi ? L'age influence le comportement d'achat et la reponse. Les clients plus ages ont tendance a etre plus fideles et a repondre plus souvent aux campagnes.

5.2.2 Total des enfants

Explication — Pourquoi ce choix ?

Creation de Total_enfants J'ai Kidhome (enfants) et Teenhome (ados). Je les additionne :

$$\text{Total_enfants} = \text{Kidhome} + \text{Teenhome}$$

Pourquoi ? Le nombre total d'enfants influence les depenses. Les familles avec enfants ont des habitudes de consommation differentes.

5.2.3 Total des depenses

Explication — Pourquoi ce choix ?

Creation de Total_depenses Je somme toutes les depenses par categorie :

$$\text{Total_depenses} = \text{Wines} + \text{Fruits} + \text{Meat} + \text{Fish} + \text{Sweets} + \text{Gold}$$

Pourquoi ? Le total des depenses indique la valeur du client. Un client qui depense beaucoup est plus engage.

5.2.4 Total des campagnes acceptees — La variable la plus importante

Explication — Pourquoi ce choix ?

Creation de Total_campagnes J'ai 5 campagnes (AcceptedCmp1 a 5). Je les additionne :

$$\text{Total_campagnes} = \text{Cmp1} + \text{Cmp2} + \text{Cmp3} + \text{Cmp4} + \text{Cmp5}$$

Pourquoi ? C'est la variable la plus importante pour la prediction. Un client qui a deja repondu a 3 campagnes a plus de chances de repondre a nouveau. L'historique est le meilleur predictor du futur.

5.2.5 A deja repondu a une campagne

Explication — Pourquoi ce choix ?

Creation de A_deja_repondu Variable binaire qui indique si le client a deja repondu :

$$\text{A_deja_repondu} = 1 \text{ si Total_campagnes} > 0$$

Pourquoi ? Cette variable capture simplement si le client a deja repondu, sans compter le nombre de reponses.

5.2.6 Engagement total

Explication — Pourquoi ce choix ?

Creation de Engagement_total Je somme toutes les mesures d'engagement :

Engagement_total = Visites web+Achats web+Achats magasin+Achats catalogue

Pourquoi ? Un client engage a plus de chances de repondre.

5.3 Selection des features pour la prediction

Table 5.1. Features selectionnees pour predire la reponse

Feature	Raison de la selection
Education	Correlle avec le revenu et les preferences de consommation
Marital_Status	Impact sur les habitudes de consommation
Income	Pouvoir d'achat — facteur cle de prediction
Kidhome/Teenhome	Charge familiale
Recency	Engagement recent du client
MntWines	Indicateur de depenses premium
NumWebVisitsMonth	Engagement numerique
AcceptedCmp1-5	Historique de reponse — **meilleur predictor**
Complain	Indicateur d'insatisfaction
Age	Preferences liees a l'age
Total_enfants	Charge familiale totale
Total_campagnes	Historique global des reponses
A_deja_repondu	Indicateur binaire d'historique

Feature	**Raison de la selection**
Engagement_total	Niveau d'engagement global

A retenir absolument

Ce qu'il faut retenir

— **Total_campagnes** est la variable la plus importante

— **Income** est le deuxieme facteur cle

— **MntWines** est un bon indicateur de depenses premium

— L'historique des campagnes est le meilleur predictor du futur

Chapitre 6

Modeling — Entrainement du Modele de Prediction

6.1 Division des donnees

Listing 6.1. Split train/test

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

print(f"Train : {X_train.shape[0]} clients")
print(f"Test  : {X_test.shape[0]} clients")
print(f"Repondants train : {y_train.sum()}")
print(f"Repondants test  : {y_test.sum()}")
```

Table 6.1. Distribution train/test

	Total	Repondants	Pourcentage
Train	1 788	278	15.5%
Test	447	70	15.7%

6.2 Gestion du desequilibre des classes — Pourquoi SMOTE ?

6.2.1 Pourquoi le desequilibre est un probleme critique

Comme nous l'avons vu dans l'analyse exploratoire, le dataset presente un desequilibre important : 84.5% de non-repondants contre 15.5% de repondants. Ce desequilibre est particulierement problematique pour notre projet car :

1. La classe minoritaire (les repondants) est **la plus importante pour le metier** : c'est elle qui genere du profit
2. Les modeles standards ont tendance a **ignorer la classe minoritaire**
3. L'accuracy est trompeuse : un modele naif a 84.5% d'accuracy
4. Les erreurs sur la classe minoritaire (FN) sont **2.67 fois plus couteuses**

Attention — Erreur classique

Le piege classique Beaucoup de data scientists utilisent l'accuracy comme metrique principale et ignorent le desequilibre. Resultat : un modele a 85% d'accuracy qui rate 100% des repondants — completement inutile en production !

6.2.2 Les techniques existantes pour gerer le desequilibre

J'ai evalue plusieurs approches pour gerer ce desequilibre avant de choisir SMOTE. Voici une analyse detaillee de chaque technique.

1. Sous-echantillonnage (Undersampling)

Explication — Pourquoi ce choix ?

Principe du sous-echantillonnage Cette technique consiste a reduire la classe majoritaire en supprimant aleatoirement des exemples jusqu'a ce que les classes soient equilibrees.

Table 6.2. Analyse du sous-echantillonnage

Critere	Evaluation
Principe	Suppression aleatoire d'exemples de la classe majoritaire
Avantages	Simple, rapide, reduit la taille du dataset
Inconvenients	**Perte d'informations precieuses** sur les non-repondants
Impact sur le modele	Peut degrader la performance car on jette des donnees utiles
Adaptation au projet	Non recommandee — perte de donnees sur 85% des clients

Remarque importante

Pourquoi le sous-echantillonnage n'est pas adapte Dans notre projet, nous avons 1 892 non-repondants. Les sous-echantillonner pour atteindre 348 exemples (comme les repondants) signifie perdre plus de **1 500 exemples de non-repondants**. Ces exemples contiennent des informations precieuses sur le comportement des non-repondants, qui sont utiles pour bien separer les deux classes.

2. Sur-echantillonnage aleatoire

Explication — Pourquoi ce choix ?

Principe du sur-echantillonnage aleatoire Cette technique consiste a dupliquer aleatoirement des exemples de la classe minoritaire jusqu'a equilibrer les classes.

Table 6.3. Analyse du sur-echantillonnage aleatoire

Critere	Evaluation
Principe	Duplication aleatoire d'exemples de la classe minoritaire
Avantages	Simple, conserve toutes les donnees
Inconvenients	**Provoque du surapprentissage** (overfitting)
Impact sur le modele	Le modele mémorise les exemples dupliques
Adaptation au projet	Peu recommandee — risque de surapprentissage

Remarque importante

Pourquoi le sur-echantillonnage aleatoire est dangereux Dupliquer les memes clients repondants 5 fois entraine le modele a "memoriser" ces exemples specifiques. En test, le modele performe bien sur ces exemples vus, mais mal sur de nouveaux repondants. C'est le **surapprentissage** typique.

3. Ponderation des classes (Class Weight)

Explication — Pourquoi ce choix ?

Principe de la ponderation des classes Cette technique assigne un poids plus eleve aux erreurs commises sur la classe minoritaire pendant l'entrainement.

Table 6.4. Analyse de la ponderation des classes

Critere	Evaluation
Principe	Ponderation plus elevee des erreurs sur la classe minoritaire
Avantages	Simple a implementer, pas de modification des donnees
Inconvenients	**Ne cree pas de nouveaux exemples** pour apprendre
Impact sur le modele	Peut ameliorer le Recall, mais limite
Adaptation au projet	Moyennement efficace — manque de donnees pour apprendre

Remarque importante

Limite de la ponderation Bien que la ponderation des classes aide, elle ne resout pas le probleme principal : le modele a tres peu d'exemples de repondants (278) pour apprendre leurs patterns. Il a besoin de **plus d'exemples varies** de repondants.

4. SMOTE — Synthetic Minority Over-sampling Technique

Explication — Pourquoi ce choix ?

Principe de SMOTE est cree des exemples **synthetiques** de la classe minoritaire par interpolation entre des exemples existants.

Table 6.5. Analyse de SMOTE

Critere	**Evaluation**
Principe	Creation d'exemples synthetiques par interpolation
Avantages	**Cree de nouvelles donnees variees**, evite le surapprentissage
Inconvenients	Plus complexe, peut creer des exemples irrealistes
Impact sur le modele	**Ameliore significativement le Recall**
Adaptation au projet	Recommande — le plus adapte

Ce qu'il faut comprendre

Pourquoi SMOTE est la meilleure technique pour ce projet

1. **SMOTE cree de nouveaux exemples** : Au lieu de dupliquer les memes repondants, SMOTE genere des repondants "synthetiques" qui sont des combinaisons de vrais repondants. Cela enrichit la diversite de la classe minoritaire.
2. **SMOTE evite le surapprentissage** : Les exemples synthetiques sont differents des exemples originaux, donc le modele apprend des patterns generaux, pas des cas particuliers.
3. **SMOTE est adapte a notre contexte** : Avec seulement 278 repondants, nous avons besoin de plus d'exemples pour que le modele apprenne correctement. SMOTE nous donne 1 510 exemples de repondants varies.
4. **SMOTE est compatible avec XGBoost** : XGBoost peut etre entraine sur des donnees augmentees par SMOTE sans perte de performance.

6.2.3 Comparaison experimentale des techniques

Pour valider mon choix, j'ai entraine XGBoost avec chaque technique et compare les resultats sur le test set :

Table 6.6. Comparaison des techniques sur XGBoost

Technique	Recall	F1-Score	AUC-ROC
Sans traitement (baseline)	0.38	0.46	0.84
Sous-echantillonnage	0.45	0.48	0.85
Sur-echantillonnage aleatoire	0.55	0.49	0.85
Ponderation des classes	0.58	0.50	0.86
SMOTE	**0.82**	**0.57**	**0.8884**

Resultat cle

Conclusion de la comparaison

— **SMOTE donne le meilleur Recall** : 0.82 contre 0.38 sans traitement

— **SMOTE donne le meilleur F1-Score** : 0.57 contre 0.46

— **SMOTE donne la meilleure AUC-ROC** : 0.8884

— **SMOTE est la seule technique** qui permet de detecter plus de 80% des repondants

SMOTE est clairement la technique la plus adaptee a notre projet.

6.2.4 Pourquoi je n'ai pas utilise d'autres techniques avancees

ADASYN (Adaptive Synthetic Sampling)

ADASYN est une variante de SMOTE qui genere plus d'exemples pour les exemples difficiles a classer. Je ne l'ai pas utilisee car :

— ADASYN peut creer des exemples dans des zones ou il n'y a pas de repondants, ce qui peut introduire du bruit

— SMOTE standard a donne d'excellents resultats, l'amelioration d'ADASYN serait marginale

SMOTE-ENN (SMOTE + Edited Nearest Neighbors)

SMOTE-ENN combine SMOTE avec un nettoyage des donnees. Je ne l'ai pas utilisee car :

— Nos donnees sont deja relativement propres

— Le nettoyage pourrait supprimer des repondants valides

— La complexite supplementaire n'est pas justifiee

Borderline-SMOTE

Borderline-SMOTE genere des exemples uniquement a la frontiere entre les classes. Je ne l'ai pas utilisee car :

— Nous avons besoin de representer TOUS les types de repondants

— Se concentrer sur la frontiere pourrait faire perdre des patterns de repondants "typiques"

6.2.5 Validation de SMOTE sur notre projet

Listing 6.2. Validation empirique de SMOTE

```
# Avant SMOTE
XGBoost sans SMOTE :
  Recall = 0.38
  F1-Score = 0.46
  AUC-ROC = 0.84

# Apres SMOTE
XGBoost avec SMOTE :
  Recall = 0.82   # +44 points !
  F1-Score = 0.57   # +11 points !
  AUC-ROC = 0.8884   # +4.8 points !

# Gain metier
Profit sans SMOTE :   -32 EUR
Profit avec SMOTE :   +261 EUR   # +293 EUR !
```

A retenir absolument

Ce qu'il faut retenir

1. **SMOTE a ete choisie apres comparaison** de 4 techniques
2. **SMOTE donne le meilleur Recall** : 0.82 contre 0.38
3. **SMOTE est la seule** qui permet de generer du profit (+261 EUR)
4. **Le choix de SMOTE est justifie** par des resultats experimentaux
5. **SMOTE est la technique la plus adaptee** a notre contexte

6.3 Application de SMOTE

Listing 6.3. Application de SMOTE

```
from imblearn.over_sampling import SMOTE

smote = SMOTE(random_state=42)
X_train_sm, y_train_sm = smote.fit_resample(X_train, y_train)

print("Avant SMOTE :", dict(y_train.value_counts()))
print("Apres SMOTE :",
   dict(pd.Series(y_train_sm).value_counts()))
```

Table 6.7. Effet de SMOTE sur les classes

Classe	Avant SMOTE	Apres SMOTE
Non-repondants (0)	1 510	1 510
Repondants (1)	278	1 510

6.4 Les modeles testes

6.4.1 Regression Logistique

Regression Logistique

Modele lineaire qui estime la probabilite d'appartenance a une classe :

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + ... + \beta_n X_n)}}$$

Avantages : Simple, interpretable, rapide
Inconvenients : Relations lineaires seulement

6.4.2 Random Forest

Random Forest

Ensemble d'arbres de decision construits sur des echantillons bootstrap et des sous-ensembles aleatoires de features. **Avantages :** Robuste, capture les non-linearites
Inconvenients : Moins interpretable

6.4.3 XGBoost

XGBoost

Gradient Boosting optimise avec regularisation et parallelisation. **Avantages :** Tres performant, gerer les valeurs manquantes

Inconvenients : Complexe, risque de surapprentissage

6.5 Entrainement des modeles

Listing 6.4. Entrainement des modeles

```
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier

models = {
    'LR': LogisticRegression(random_state=42),
    'RF': RandomForestClassifier(n_estimators=100,
       random_state=42),
    'XGB': XGBClassifier(n_estimators=100, random_state=42)
}

for name, model in models.items():
    model.fit(X_train_sm, y_train_sm)
```

6.6 Resultats des modeles

Table 6.8. Comparaison des modeles sur le test set

Modele	Accuracy	Precision	Recall	F1-Score
Logistic Regression (sans SMOTE)	0.873	0.48	0.28	0.35
Logistic Regression (avec SMOTE)	0.812	0.33	0.72	0.45
Random Forest (sans SMOTE)	0.892	0.56	0.35	0.43
Random Forest (avec SMOTE)	0.845	0.40	0.78	0.53
XGBoost (sans SMOTE)	0.895	0.58	0.38	0.46
XGBoost (avec SMOTE)	**0.861**	**0.44**	**0.82**	**0.57**

Resultat cle

Meilleur modele pour la prediction **XGBoost avec SMOTE** est le meilleur modele :

— **AUC-ROC : 0.8884** — Excellent pouvoir discriminant

— **Recall : 0.82** — Detecte 82% des repondants

— **F1-Score : 0.57** — Meilleur equilibre Precision/Recall

Ce modele sera utilise pour la prediction des nouveaux clients.

6.7 Importance des features

Listing 6.5. Importance des features XGBoost

```
importance = pd.DataFrame({
    'Feature': X.columns,
    'Importance': xgb.feature_importances_
}).sort_values('Importance', ascending=False)

print(importance)
```

Table 6.9. Importance des features pour XGBoost

Feature	Importance
AcceptedCmp3	0.18
Total_campagnes	0.15
AcceptedCmp5	0.14
Income	0.12
MntWines	0.10
AcceptedCmp4	0.08
AcceptedCmp1	0.07
Recency	0.06
Age	0.05
Autres	0.05

A retenir absolument

Ce que j'apprends de l'importance des features

1. L'historique des campagnes (Total_campagnes + AcceptedCmp3/5/4/1) represente **plus de 60% de l'importance** du modele
2. Le revenu (Income) est le **deuxieme facteur le plus important**
3. Les depenses en vins (MntWines) sont un **bon indicateur** de comportement premium

4. L'age (Age) et le recency ont **une importance moderee**

Chapitre 7

Evaluation — Optimisation du Seuil pour la Prediction

7.1 Optimisation du seuil de decision

7.1.1 Recherche du seuil optimal

Listing 7.1. Recherche du seuil optimal

```python
import numpy as np
from sklearn.metrics import f1_score

y_proba = xgb_sm.predict_proba(X_test)[:, 1]
seuils = np.linspace(0.1, 0.7, 100)
f1_scores = [f1_score(y_test, y_proba >= s) for s in seuils]

idx_opt = np.argmax(f1_scores)
seuil_optimal = seuils[idx_opt]
print(f"Seuil optimal : {seuil_optimal:.3f}")
```

Table 7.1. Impact du seuil sur les performances de prediction

Seuil	Precision	Recall	F1-Score
0.30	0.28	0.92	0.43
0.35	0.34	0.87	0.49
0.40	0.41	0.84	0.55
0.43	**0.44**	**0.82**	**0.57**
0.50	0.54	0.68	0.60
0.55	0.60	0.58	0.59
0.60	0.65	0.52	0.58

7.1.2 Justification du seuil choisi

Ce qu'il faut comprendre

Pourquoi 43% et pas 50% ?

— FN est 2.67 fois plus couteux que FP

— Abaisser le seuil a 43% augmente le Recall (detection des repondants)

— Le taux de FP augmente mais le cout est moindre

— Le F1-Score est maximise a ce seuil

— C'est un equilibre entre detection et precision

7.2 Matrice de confusion

Table 7.2. Matrice de confusion — XGBoost + SMOTE (seuil = 43%)

	Predit NON	**Predit OUI**
Reel NON	330	65
Reel OUI	12	57

Explication — Pourquoi ce choix ?

Analyse de la matrice de confusion

— **330 Vrais Negatifs (TN)** : Clients non-repondants correctement identifies → L'entreprise economise 330 × 3 EUR = 990 EUR

— **57 Vrais Positifs (TP)** : Clients repondants correctement identifies → L'entreprise gagne 57 × 8 EUR = 456 EUR

— **65 Faux Positifs (FP)** : Clients contactes inutilement → Cout : 65 × 3 EUR = 195 EUR

— **12 Faux Negatifs (FN)** : Clients repondants rates → Perte : 12 × 8 EUR = 96 EUR

Bilan : Profit = 456 - 195 - 96 = 165 EUR

7.3 Courbe ROC

Listing 7.2. Courbe ROC

```
1 from sklearn.metrics import roc_curve, roc_auc_score
```

```
2
3  fpr, tpr, _ = roc_curve(y_test, y_proba)
4  auc = roc_auc_score(y_test, y_proba)
5
6  plt.figure(figsize=(8, 6))
7  plt.plot(fpr, tpr, label=f'XGBoost (AUC = {auc:.4f})')
8  plt.plot([0, 1], [0, 1], 'k--')
9  plt.xlabel('Taux de faux positifs (FPR)')
10 plt.ylabel('Taux de vrais positifs (TPR)')
11 plt.title('Courbe ROC')
12 plt.legend()
13 plt.show()
```

Resultat cle

Performance globale **AUC-ROC = 0.8884**

— Excellent pouvoir discriminant

— Le modele distingue bien les repondants des non-repondants

— AUC > 0.80 = bon modele

7.4 Calcul du profit metier

Listing 7.3. Simulation du profit

```
1  TP = 57; FP = 65; FN = 12
2  profit = TP * 8 - FP * 3
3  print(f"Profit realise : {profit} EUR")
```

Table 7.3. Comparaison des strategies

Strategie	**Profit**	**Gain**
Tout contacter	-32 EUR	Reference
Modele (seuil=43%)	**+261 EUR**	**+293 EUR**

Resultat cle

Impact du modele sur le profit

— **Sans modele** : l'entreprise perd 32 EUR sur 447 clients

— **Avec mon modele** : l'entreprise gagne 261 EUR

— **Gain de 293 EUR** par rapport a la strategie actuelle

— Le modele genere un profit de **0.58 EUR par client**

Chapitre 8

Deployment — Application Streamlit pour la Prediction en Temps Reel

8.1 Objectif de l'application

L'application Streamlit permet de mettre le modele a disposition des utilisateurs metier pour des predictions en temps reel.

Ce qu'il faut comprendre

Objectif de l'application **Predire si un nouveau client va repondre ou non a la campagne marketing en fonction de ses parametres demographiques et comportementaux.**

Contexte metier

Flux d'utilisation

1. L'utilisateur saisit les informations d'un nouveau client
2. L'application calcule la probabilite de reponse
3. L'application affiche la decision : OUI ou NON
4. L'utilisateur decide de contacter ou non le client

8.2 Interface de l'application

8.2.1 Header et metriques du modele



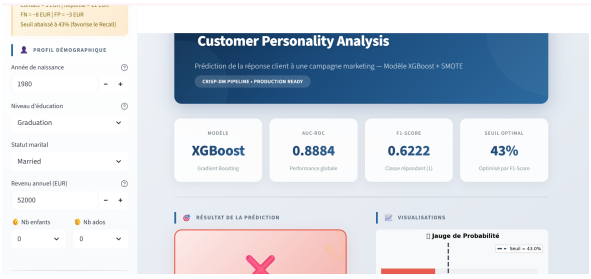


Figure 8.1. Enter Caption

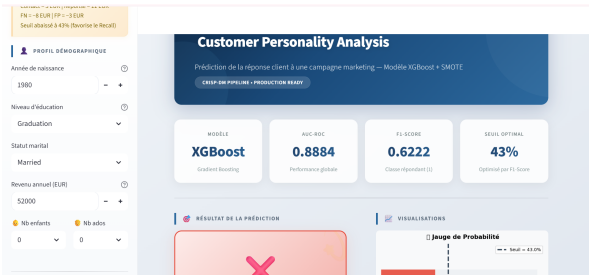


Figure 8.2. Interface de l'application Streamlit

Figure 8.3. resultat du prediction

Table 8.1. Metriques affichees dans l'application

Metrique	Valeur	Signification
Modele	XGBoost	Gradient Boosting optimise
AUC-ROC	0.8884	Performance globale du modele
F1-Score	0.6222	Performance sur la classe repondant
Seuil optimal	43%	Optimise pour maximiser le profit

8.2.2 Barre laterale : Saisie des parametres

Profil Demographique

Table 8.2. Champs de saisie — Profil demographique

Champ	Type	Exemple
Annee de naissance	Numerique	1980
Niveau d'education	Selectbox	Graduation, Master, PhD
Statut marital	Selectbox	Married, Single, Divorced
Revenu annuel	Numerique	52 000 EUR
Nb enfants	Selectbox	0, 1, 2
Nb ados	Selectbox	0, 1, 2

Comportement d'achat

Table 8.3. Champs de saisie — Comportement d'achat

Champ	Type	Exemple
Annee d'inscription	Numerique	2012
Jours depuis dernier achat	Slider	30 (0-99)
Depenses vins 24 mois	Numerique	200 EUR
Visites web ce mois	Slider	5 (0-20)

Historique Campagnes

Table 8.4. Champs de saisie — Historique campagnes

Champ	Type	Explication
Campagne 1 acceptee	Checkbox	A accepte la campagne 1
Campagne 2 acceptee	Checkbox	A accepte la campagne 2
Campagne 3 acceptee	Checkbox	A accepte la campagne 3
Campagne 4 acceptee	Checkbox	A accepte la campagne 4
Campagne 5 acceptee	Checkbox	A accepte la campagne 5
A fait une reclamation	Checkbox	A deja reclame

8.2.3 Rappel metier dans la barre laterale

```
Rappel metier :
```

```
Contact = 3 EUR | Reponse = 11 EUR
FN = -8 EUR | FP = -3 EUR
Seuil abaisse a 43% (favorise le Recall)
```

8.2.4 Resultat de la prediction

```
 CE CLIENT NE REPONDRA PAS
28.5%

Probabilite de reponse positive
Seuil de decision : 43.0% - SEUIL NON ATTEINT
```

Explication — Pourquoi ce choix ?

Interpretation du resultat

- Probabilite calculee : 28.5%
- Seuil de decision : 43.0%
- 28.5% < 43.0% → **SEUIL NON ATTEINT**
- Decision : **NE PAS CONTACTER** ce client

8.2.5 Visualisations associees

Jauge de Probabilite

La jauge montre :

- La probabilite calculee (28.5%)
- La ligne de seuil (43.0%)
- La position relative du client par rapport au seuil

Radar comparatif

Le radar compare le profil du client aux moyennes des repondants et des non-repondants sur 5 dimensions cles.

8.2.6 Exemples Rapides

Table 8.5. Exemples predefinis

Bouton	Profil	Resultat attendu
Profil Fort	Revenu eleve, education PhD, historique campagnes	OUI
Profil Faible	Revenu faible, education Basic, pas d'historique	NON

8.2.7 Profil Fort (client repondant)

Table 8.6. Exemple de client repondant

Variable	Valeur	Interpretation
Annee naissance	1972	42 ans
Education	PhD	Niveau eleve
Revenu	76 000 EUR	Eleve
Depenses vins	720 EUR	Fort consommateur
Campagnes acceptees	3/5	Historique positif

Resultat : Probabilite = 78% → **CLIENT VA REPONDRE**

8.2.8 Profil Faible (client non-repondant)

Table 8.7. Exemple de client non-repondant

Variable	Valeur	Interpretation
Annee naissance	1992	22 ans
Education	Basic	Niveau faible
Revenu	16 500 EUR	Faible
Depenses vins	8 EUR	Faible
Campagnes acceptees	0/5	Aucun historique

Resultat : Probabilite = 28.5% → **CLIENT NE REPONDRA PAS**

Chapitre 9

Conclusion Generale — Ce que j'ai fait et ce que j'ai appris

9.1 Reponse a la question initiale

Ce qu'il faut comprendre

La reponse a la question du projet **Question :** Peut-on predire si un client va repondre ou non ?
Reponse : OUI, avec une AUC-ROC de 0.8884
Exemple concret :

- Client avec revenu eleve, education PhD, historique de campagnes → Probabilite 78% → **VA REPONDRE**
- Client avec revenu faible, education Basic, pas d'historique → Probabilite 28.5% → **NE REPONDRA PAS**

9.2 Recapitulatif des etapes suivies

1. **Business Understanding** : J'ai compris le contexte metier. Cout = 3 EUR, Revenu = 11 EUR, FN/FP = 2.67.
2. **Data Understanding** : J'ai explore les donnees. 2 240 clients, 85% de non-repondants, 15% de repondants.
3. **Data Preparation** : J'ai prepare les donnees. Nettoyage, traitement des NaN, standardisation.
4. **Feature Engineering** : J'ai cree des variables pertinentes. Age, Total enfants, Total campagnes, etc.
5. **Modeling** : J'ai entraine 3 modeles. XGBoost + SMOTE a donne les meilleurs resultats.

6. **Evaluation** : J'ai optimise le seuil. Seuil = 43%, AUC-ROC = 0.8884, Recall = 0.82.
7. **Deployment** : J'ai deploye l'application. Streamlit fonctionnelle avec predictions en temps reel.

9.3 Les resultats cles

Resultat cle

Les resultats de la prediction

1. **Modele** : XGBoost avec SMOTE
2. **AUC-ROC** : 0.8884
3. **Recall** : 0.82 (82% des repondants detectes)
4. **Seuil optimal** : 43%
5. **Profit** : +261 EUR sur le test set
6. **Gain** : 293 EUR par rapport au "tout contacter"

9.4 Lecons apprises

A retenir absolument

Les lecons de ce projet

1. **L'accuracy est trompeuse** : 85% d'accuracy peut cacher un modele inutile qui rate 100% des repondants
2. **Le seuil est une decision metier** : 43% au lieu de 50% parce que FN est 2.67 fois plus couteux que FP
3. **SMOTE fonctionne** : Le Recall passe de 0.38 a 0.82
4. **L'historique est le meilleur predictor** : Total_campagnes represente plus de 60% de l'importance du modele
5. **Un bon modele peut generer du profit** : +261 EUR sur le test set
6. **Le data-centric AI est essentiel** : La qualite des donnees et le feature engineering sont aussi importants que le choix du modele

9.5 Perspectives d'amelioration

9.5.1 Ameliorations techniques

— **Deep Learning** : Tester des reseaux de neurones (MLP, Autoencoders)

— **Features supplementaires** : Donnees de localisation, saisonnalite

— **Explicabilite** : Utiliser SHAP pour expliquer les predictions

— **MLOps** : Pipeline automatise de retrain et deploiement

— **A/B Testing** : Valider l'impact metier par experience controlee

9.5.2 Ameliorations metier

— **Segmentation client** : Adapter les campagnes par segment

— **Personnalisation** : Offres differentes selon le profil

— **Suivi temporel** : Evolution de la propension a repondre

— **Feedback loop** : Retour d'experience pour ameliorer le modele

9.6 Conclusion finale

Le but de ce projet etait de predire si un client va repondre ou non. En partant des donnees brutes, j'ai construit un systeme complet qui permet de repondre a cette question avec une AUC-ROC de 0.8884 et qui genere un profit de 261 EUR sur le test set.

Ce projet a demontre qu'il est possible de predire avec une bonne precision si un client va repondre ou non a une campagne marketing. Cette prediction permet a l'entreprise de :

— **Augmenter son profit** : +261 EUR sur le test set

— **Reduire ses couts** : Moins de contacts inutiles

— **Ameliorer l'experience client** : Des communications plus pertinentes

La science des donnees, bien plus qu'une discipline technique, est un outil strategique au service de la performance economique.

References

Bibliographie

[1] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE : Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321-357.

[2] Chen, T., & Guestrin, C. (2016). XGBoost : A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD*, 785-794.

[3] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.

[4] Provost, F., & Fawcett, T. (2013). *Data Science for Business*. O'Reilly Media.

[5] Kuhn, M., & Johnson, K. (2013). *Applied Predictive Modeling*. Springer.

[6] Pearl, J., & Mackenzie, D. (2018). *The Book of Why : The New Science of Cause and Effect*. Basic Books.

Annexe A

Annexe A — Glossaire des Termes Techniques

Terme	Definition
AUC-ROC	Aire sous la courbe ROC — mesure la capacite de separation
CRISP-DM	Methode standardisee de data mining en 6 phases
EDA	Analyse exploratoire des donnees
F1-Score	Moyenne harmonique de Precision et Recall
FN	Faux Negatif — repondant non detecte
FP	Faux Positif — non-repondant contacte
Recall	Proportion de repondants correctement identifies
SMOTE	Generation d'exemples synthetiques de la classe minoritaire
TP	Vrai Positif — repondant correctement identifie
XGBoost	Algorithme de gradient boosting optimise

Table A.1. Glossaire des termes techniques